

### 纲要

- **一** 系统简介
- 三 系统组成
- 三》系统演示
- 四)前期工作小结
- 五〉下一步工作

- ▶ 基于Hadoop系统的文本处理
- ➤ 基于Nutch的Framework创建
- > 提供Eclipse插件来支持用户开发
- ➤ 通过Web方式进行运行维护管理

- > 30台双路四核商用服务器
  - ✓ Intel(R) Xeon(R) CPU E5450 @ 3.00GHz
  - ✓ 16GB内存
  - ✓ 8x500GB SAS硬盘
- ➤ 网络: 20Gb/s IB网十千兆以太网

> 操作系统

Red Hat Enterprise Linux AS release 4 (Nahant Update 7)

〉内核


2.6.9-78.ELsmp SMP x86\_64

### > 应用软件

- ✓ Java(TM) SE Runtime Environment (build 1.6.0\_13-b03)
- ✓ gcc version 3.4.6 20060404 (Red Hat 3.4.6-10)
- > Hadoop版本

hadoop-0.12.2-core-jn.jar(补丁版本)


### 海量文本处理系统



- > 数据接收
  - ✓ 支持文件和网络数据流两种方式
  - ✓ 采用数据网关代理模式,将接收到的数据直接保存到HDFS中
  - ✓ 4台接收机,每台机器支持10个进程 进行接收和写入,复制因子为3
  - ✓ 经过测试,单机写入速度总带宽为 70MB/s

- > 分布式运行支撑环境
  - ✓ 基于hadoop的Map/Reduce
  - ✓ 数据块大小设置为128M
  - ✓ 使用4个hadoop实例,每个实例在每台 机器上启动2个任务进程
  - ✓ 经过测试,单机处理速度达到4MB/s

- > 应用服务
  - ✓ 数据迁移服务
  - ✓ 索引合并服务
  - ✓ 数据清洗服务
  - ✓ 全文检索服务
  - ✓ 统计服务



### 数据接收

用户:dreceiver 节点:cn125-cn128

cn125



运行中...

cn126



运行中...

cn127



运行中...

cn128



运行中...

### 基础环境

主结点:cn122

运算结点:cn123-cn124

用户:dguest1 dguest2 dguest3 dguest4



dguest1:9060





dguest2:9070





dguest3:9080

运行中...

dguest4:9090

### 运行管理

主结点:cn122

运算结点:cn123-cn124

用户:dguest1 dguest2 dguest3 dguest4







dguest2:9070



dguest3:9080



dguest4:9090

### 网络服务

查询服务 cn121



运行中... iipg:8080

推送服务 cn121



运行中... iipg:8080

### WSA 服务

cn121



运行中...

cn121




运行中...

### 三、系统演示



### 三、系统演示

2010-09-03 17:08:20,425 INFO plugin PluginRepository - Ontology Model Loader (orc 2010-09-03 17:08:21,316 INFO fetcher.EmlFetcher - No more data, wait for another I



2010-09-03 17:08:18,493 INFO plugin PluginRepository - Ontology Model Loader (or 2010-09-03 17:08:19,860 INFO fetcher,EmlFetcher - No more data, wait for another I

# 四、前期工作小结

- ➤ 针对0.12版本的Hadoop进行的高可用性修正
- ➤ 从Nutch的Framework出发创建了文本流数据处理的基础框架
- ➤ 开发了Eclipse插件来简化应用开发和 部署

## 五、下一步工作

- ▶ 基于Hadoop的优化,包括:
  - ✓ 自动化的数据均衡
  - ✓ 多道任务间的高效数据交换
  - ✓ 实现任务流水化调度机制
- ➤ 面向云服务器使用模式开发Eclipse插 件,支持应用的开发和调试

